

Segmentación de Imágenes SEM mediante AutoML: Comparación de Estrategias de Segmentación

Autor

Resumen—Se presenta un enfoque de aprendizaje automático para la detección de zonas frágiles y dúctiles en imágenes obtenidas mediante microscopía electrónica de barrido. El estudio compara modelos del estado del arte basados en transformers con estrategias de segmentación propuestas, integradas en un framework AutoML. La selección del modelo se realiza a partir de métricas de desempeño relevantes, considerando explícitamente las limitaciones computacionales del entorno de ejecución. Los resultados muestran la viabilidad del enfoque bajo recursos restringidos y evidencian el impacto del uso de aumentación de datos y transferencia de aprendizaje en la calidad de la segmentación.

I. INTRODUCCIÓN

La caracterización de los mecanismos de fractura en materiales es un problema central en la ciencia e ingeniería de materiales, debido a su impacto directo en la evaluación del desempeño mecánico y la confiabilidad estructural. En particular, la identificación de zonas asociadas a comportamientos frágiles y dúctiles a partir de microestructuras proporciona información clave para el análisis del fallo y el diseño de materiales.

Las imágenes obtenidas mediante microscopía electrónica de barrido (SEM) constituyen una de las principales herramientas para el estudio de superficies de fractura y microestructuras. No obstante, el análisis tradicional de este tipo de imágenes se basa en inspección visual experta, lo cual introduce subjetividad, limita la reproducibilidad de los resultados y dificulta su aplicación a grandes volúmenes de datos.

En este contexto, las técnicas de aprendizaje automático y, en particular, los modelos de visión por computador han mostrado un potencial significativo para automatizar tareas de clasificación y segmentación en imágenes complejas. Recientemente, modelos basados en transformers, como Vision Transformer (ViT) y Swin Transformer, han alcanzado resultados destacados en diversas tareas de análisis de imágenes, posicionándose como referentes del estado del arte. Sin embargo, su aplicación práctica suele estar condicionada por la disponibilidad de datos anotados y recursos computacionales elevados.

Estas limitaciones motivan la exploración de estrategias alternativas que permitan aprovechar modelos de alto desempeño bajo restricciones de cómputo y datos. En este trabajo se consideran tanto modelos del estado del arte como enfoques propuestos basados en la descomposición espacial de la imagen y el uso de clasificadores preentrenados, con el objetivo de transferir conocimiento desde tareas de clasificación hacia problemas de segmentación.

Adicionalmente, se adopta un enfoque AutoML para automatizar la selección de modelos y el ajuste de hiperparámetros, empleando metaheurísticas y considerando explícitamente las restricciones impuestas por un entorno de cómputo limitado. El objetivo de este estudio es evaluar la viabilidad y el desempeño de estas estrategias para la detección de zonas frágiles y dúctiles en imágenes SEM, comparando modelos del estado del arte con enfoques alternativos bajo condiciones realistas de entrenamiento y evaluación.

II. METODOLOGÍA

III. DESCRIPCIÓN DEL DATASET

IV. ESTRATEGIAS DE SEGMENTACIÓN

La segmentación de zonas frágiles y dúctiles se aborda mediante un conjunto de estrategias complementarias que responden a distintos niveles de complejidad y granularidad en la representación de la imagen. En primer lugar, se consideran arquitecturas basadas en Vision Transformers y Swin Transformers, seleccionadas por su capacidad para modelar dependencias espaciales de largo alcance y por su consolidación como enfoques de referencia en tareas de segmentación densa. Estos modelos permiten aprender representaciones globales y jerárquicas directamente a partir de la imagen completa, proporcionando una base sólida para la identificación precisa de regiones con comportamiento mecánico diferenciado.

De forma complementaria, se exploran estrategias de segmentación indirecta que reutilizan conocimiento previamente adquirido en tareas de clasificación. En este enfoque, la información semántica extraída por modelos entrenados para discriminar regiones frágiles y dúctiles se emplea como guía para definir esquemas de segmentación basados en particiones espaciales adaptativas. En particular, se consideran métodos que descomponen la imagen en regiones locales cuya resolución y extensión se ajustan dinámicamente en función de la complejidad visual y la confianza de la clasificación, permitiendo una transición controlada entre análisis global y local.

Este planteamiento unifica modelos de segmentación directa y estrategias guiadas por clasificación bajo un mismo marco conceptual, facilitando la comparación entre enfoques de distinta naturaleza y sentando las bases para la incorporación progresiva de métodos alternativos de particionado espacial en subsecciones posteriores.

IV-A. Vision Transformer (ViT)

La segmentación se aborda mediante un modelo basado en Vision Transformers (ViT) adaptado a un esquema enco-

der-decoder, diseñado para producir mapas de segmentación densos a partir de imágenes de entrada en escala de grises.

El modelo recibe como entrada imágenes bidimensionales de tamaño fijo, representadas como tensores con uno o más canales. En los casos en que la entrada no coincide con el número de canales esperado, se aplica una conversión a escala de grises para garantizar compatibilidad. La salida del modelo consiste en un tensor de segmentación multiclase, donde cada píxel es asignado a una de las clases definidas. Durante la inferencia, estas salidas se transforman en máscaras discretas mediante una operación de selección de la clase más probable por píxel.

El proceso comienza con una etapa de patch embedding, en la cual la imagen se divide implícitamente en regiones no solapadas de tamaño uniforme. Cada región se proyecta a un espacio latente de dimensión fija, generando una secuencia de representaciones que conserva la información espacial global. A estas representaciones se les añaden embeddings posicionales aprendibles, lo que permite al modelo mantener la noción de localización relativa entre parches.

La secuencia resultante se procesa mediante un codificador Transformer compuesto por múltiples capas de autoatención multi-cabeza y bloques feed-forward. Esta etapa permite modelar dependencias de largo alcance y capturar relaciones contextuales globales, lo cual es especialmente relevante en imágenes con estructuras complejas y patrones no locales.

Tras el codificador, las representaciones latentes se reorganizan nuevamente en una estructura espacial bidimensional. A continuación, un decodificador convolucional progresivo realiza una serie de operaciones de refinamiento y reescalado espacial, incrementando gradualmente la resolución hasta alcanzar el tamaño original de la imagen. Esta etapa traduce la información global extraída por el Transformer en predicciones locales coherentes a nivel de píxel.

El entrenamiento se lleva a cabo de extremo a extremo mediante una función de pérdida de entropía cruzada multiclase, optimizando directamente la correspondencia entre las predicciones del modelo y las máscaras de referencia. La evaluación produce pares de máscaras predichas y reales, lo que permite un análisis cualitativo y cuantitativo del desempeño del modelo en tareas de segmentación.

En conjunto, esta arquitectura combina la capacidad de los Vision Transformers para modelar contexto global con la precisión espacial de decodificadores convolucionales, resultando adecuada para problemas de segmentación.

IV-B. Swin Transformer

La estrategia de segmentación basada en Swin Transformers se apoya en una arquitectura jerárquica de atención local con ventanas desplazadas, adaptada para producir mapas de segmentación densos a partir de imágenes de microscopía electrónica.

El modelo recibe como entrada imágenes bidimensionales de tamaño fijo, representadas como tensores en escala de grises. En casos donde la información de entrada presenta múltiples canales, se aplica una conversión previa para garantizar consistencia con la arquitectura. La salida del modelo es

un mapa de segmentación multiclase con la misma resolución espacial que la imagen de entrada, en el que cada píxel es asignado a una de las clases consideradas.

El procesamiento se inicia mediante una etapa de patch embedding jerárquica, en la cual la imagen se descompone en parches de pequeño tamaño que son proyectados a un espacio latente inicial. A diferencia de los Vision Transformers clásicos, el modelo Swin organiza estas representaciones en una estructura piramidal de múltiples etapas, donde la resolución espacial se reduce progresivamente y la dimensión de las características aumenta. En cada etapa, la atención se calcula de forma local dentro de ventanas, alternando ventanas fijas y desplazadas, lo que permite capturar dependencias espaciales tanto locales como de mayor alcance con un costo computacional controlado.

Las características extraídas por el backbone Swin corresponden a una representación de baja resolución espacial pero alta riqueza semántica. Para su uso en segmentación densa, estas representaciones se reorganizan y se adaptan mediante una etapa intermedia de refinamiento y reescalado, con el objetivo de armonizar la resolución con la del decodificador.

Posteriormente, un decodificador convolucional progresivo reconstruye la resolución original de la imagen. Este decodificador realiza una serie de operaciones de convolución, normalización y reescalado espacial, transformando las representaciones latentes jerárquicas en predicciones a nivel de píxel. La última proyección produce un conjunto de mapas de probabilidad, uno por clase, que se convierten en máscaras discretas mediante una asignación por máxima probabilidad.

El modelo se entrena de extremo a extremo utilizando una función de pérdida de entropía cruzada multiclase, optimizando directamente la coherencia entre las máscaras predichas y las anotaciones de referencia. Durante la evaluación, el modelo genera pares de máscaras predichas y reales, lo que permite analizar su desempeño tanto de forma cuantitativa como cualitativa.

Esta estrategia aprovecha la naturaleza jerárquica y la atención localizada del Swin Transformer para modelar de manera eficiente estructuras complejas a múltiples escalas, resultando especialmente adecuada para tareas de segmentación en imágenes con alta variabilidad textural y patrones multiescala.

IV-C. Quadtree

La estrategia de segmentación basada en quadtree adopta un enfoque jerárquico y recursivo, en el cual la imagen se descompone progresivamente en regiones cuadradas de menor tamaño en función de la confianza de un clasificador subyacente. Este método no pertenece al estado del arte en segmentación, pero permite reutilizar modelos de clasificación preentrenados para abordar tareas de segmentación bajo restricciones computacionales.

El modelo opera sobre imágenes de tamaño fijo y genera máscaras de segmentación a nivel de píxel mediante la clasificación iterativa de regiones. Cada región es evaluada por un clasificador que asigna una etiqueta y una confianza asociada. Si la confianza supera un umbral predefinido, la región se considera homogénea y se asigna directamente a la máscara

de salida. En caso contrario, la región se subdivide en cuatro cuadrantes, repitiendo el proceso de forma recursiva.

El criterio de parada de la recursión se define por tres condiciones: alcanzar un nivel mínimo de confianza, llegar a un tamaño mínimo de región o exceder una profundidad máxima de subdivisión. De esta forma, el modelo equilibra precisión espacial y costo computacional, evitando una subdivisión excesiva en regiones con información limitada.

El proceso de entrenamiento se divide conceptualmente en dos etapas. En primer lugar, el clasificador utilizado por el esquema quadtree es entrenado de manera independiente empleando un conjunto de datos de clasificación externo. Este clasificador puede estar basado en redes convolucionales, arquitecturas transformer o cualquier otro modelo, lo que permite transferir conocimiento desde tareas de clasificación hacia la segmentación.

En segundo lugar, el modelo de segmentación ajusta sus hiperparámetros estructurales, en particular el umbral de confianza, el tamaño mínimo de región y la profundidad máxima del quadtree. Cuando se habilita el modo AutoML, estos hiperparámetros son optimizados mediante una metaheurística de recocido simulado (simulated annealing), utilizando un subconjunto de validación derivado del dataset de segmentación. La optimización se guía por una métrica seleccionada previamente, permitiendo adaptar el comportamiento del quadtree al compromiso deseado entre detalle espacial y generalización.

Una vez finalizado el proceso de optimización, el modelo se configura con la mejor combinación de hiperparámetros encontrada y se evalúa sobre el conjunto completo de entrenamiento.

V. MODELOS DE CLASIFICACIÓN PARA SEGMENTACIÓN

En esta sección se describen los modelos de clasificación empleados como componentes fundamentales de las estrategias de segmentación guiada basadas en particionado espacial. A diferencia de los enfoques de segmentación directa, estos métodos delegan la toma de decisiones semánticas a clasificadores entrenados para discriminar entre zonas frágiles y dúctiles, cuya salida se utiliza posteriormente para construir máscaras de segmentación a distintas escalas.

El objetivo de esta sección es caracterizar los clasificadores utilizados, independientemente del esquema de particionado específico en el que se integran. De este modo, se separa explícitamente el análisis del modelo de clasificación del mecanismo geométrico de segmentación, permitiendo evaluar de forma aislada el impacto de la arquitectura del clasificador en el desempeño final del sistema. Las subsecciones siguientes presentan los distintos modelos considerados.

V-A. Clasificador CNN

El clasificador basado en Redes Neuronales Convolucionales (CNN) fue diseñado para clasificar regiones de tamaño variable extraídas por el algoritmo Quadtree.

La arquitectura sigue un patrón de extracción de características seguido de clasificación:

$$\begin{aligned} \text{Entrada} &\rightarrow \text{Bloques Conv.} \rightarrow \text{Pooling Global} \\ &\rightarrow \text{Clasificador} \rightarrow \text{Softmax} \end{aligned} \quad (1)$$

Cada bloque convolucional aplica la siguiente secuencia:

1. Convolución 3×3 con padding=1
2. Batch Normalization
3. Activación ReLU
4. Convolución 3×3 con padding=1
5. Batch Normalization
6. Activación ReLU
7. Max Pooling 2×2 con stride=2

Se usa un kernel de 3×3 porque es el tamaño mínimo que captura información espacial (arriba, abajo, izquierda, derecha y diagonales). Al apilar múltiples capas con kernels pequeños se obtiene un campo receptivo grande con menos parámetros que usando un kernel grande directamente.

El padding de 1 píxel mantiene las dimensiones espaciales constantes después de cada convolución, lo que simplifica el diseño de la red.

Batch Normalization se incluye para acelerar el entrenamiento y estabilizar los gradientes, permitiendo usar tasas de aprendizaje más altas.

Se usan dos convoluciones por bloque antes del pooling para aumentar la capacidad de la red sin reducir las dimensiones espaciales prematuramente.

El parámetro `num_blocks` controla la profundidad de la red. Como cada bloque reduce las dimensiones a la mitad mediante Max Pooling, el tamaño mínimo de entrada es $2^n \times 2^n$ píxeles, donde n es el número de bloques.

Cuadro I
RELACIÓN ENTRE NÚMERO DE BLOQUES Y TAMAÑO MÍNIMO DE ENTRADA

num_blocks	Tamaño mínimo	Canales finales
2	4×4	64
3	8×8	128
4	16×16	256
5	32×32	512

El valor por defecto es 3 bloques, lo que permite clasificar regiones de 8×8 píxeles. Este tamaño fue elegido porque el Quadtree puede subdividir hasta regiones pequeñas, y 8×8 se consideró suficiente para contener información visual distinguible mientras permite segmentación detallada.

El número de filtros se duplica en cada bloque, comenzando desde 32:

$$\text{filtros en bloque } i = 32 \times 2^{i-1} \quad (2)$$

Esta progresión compensa la reducción de dimensiones espaciales: a medida que la imagen se hace más pequeña, se aumentan los canales para mantener la capacidad de representación.

Antes de la clasificación se aplica `AdaptiveAvgPool2d((1,1))`, que reduce cualquier tamaño espacial a 1×1 calculando el promedio de cada canal.

Esta capa permite que la red acepte entradas de cualquier tamaño (siempre que cumplan el mínimo). Sin importar si la entrada es 8×8 o 256×256, la salida siempre es un vector de tamaño fijo que puede procesarse por las capas densas.

La cabeza de clasificación consiste en:

1. Aplanamiento del tensor

2. Dropout (50 %)
3. Capa densa con reducción a 1/4 de los canales
4. Activación ReLU
5. Dropout (25 %)
6. Capa densa final a 3 clases

El Dropout previene sobreajuste, que es una preocupación con datasets pequeños de imágenes SEM. La capa intermedia reduce la dimensionalidad gradualmente antes de la clasificación final.

La red produce probabilidades mediante Softmax, donde la probabilidad más alta indica la clase predicha y su valor representa la confianza. Esta confianza es usada por el Quadtree para decidir si subdividir la región o aceptar la clasificación.

El entrenamiento usa Cross-Entropy Loss y el optimizador Adam. Las imágenes se agrupan por tamaño para formar batches, ya que las regiones del Quadtree tienen dimensiones variables y solo se pueden apilar en un tensor imágenes del mismo tamaño.

V-A1. Clasificador ViT

V-B. Pipeline de Aumentación de Datos

Se implementó un conjunto completo de técnicas de aumentación de datos con el objetivo de incrementar la diversidad del dataset y mejorar la generalización de los modelos. La estrategia combinó transformaciones geométricas, fotométricas y específicas para SEM, aplicadas de manera secuencial y probabilística según un pipeline de aumentación.

V-B1. Aumentaciones Geométricas

Afectan tanto a imágenes como a máscaras, manteniendo la alineación espacial:

- Rotación: Rota la imagen y la máscara dentro de un rango definido, simulando diferentes orientaciones de la muestra.
- Volteo: Invierte horizontal o verticalmente.
- Escalado: Realiza zoom in/out manteniendo el tamaño original.
- Traslación: Desplaza la imagen y máscara horizontal y/o verticalmente.
- Recorte aleatorio: Extrae subregiones aleatorias, redimensionadas al tamaño original.

Estas transformaciones permiten al modelo generalizar a variaciones espaciales de la muestra.

V-B2. Aumentaciones Fotométricas

Modifican únicamente las imágenes, simulando variaciones en iluminación y ruido, sin afectar las máscaras:

- Brillo.
- Contraste.
- Corrección gamma.
- Ruido gaussiano.
- Desenfoque gaussiano.

Estas técnicas permiten al modelo aprender invariancia frente a condiciones de adquisición o ruido instrumental.

V-B3. Aumentaciones Específicas para SEM

Diseñadas para capturar artefactos y características típicas de imágenes SEM:

- Deformación elástica (ElasticDeformationAugmentator): Simula variaciones naturales en texturas de roca o deformaciones durante la adquisición.

- Ecualización adaptativa de histograma (AdaptiveHistogramEqualizationAugmentator): Mejora contraste local mediante CLAHE.
- Artefactos de carga: Añade manchas típicas de muestras no conductivas.
- Ruido de líneas de escaneo (ScanLineNoiseAugmentator): Simula líneas de escaneo o barrido que aparecen en SEM.

Estas técnicas aumentan la robustez del modelo frente a artefactos específicos de la microscopía electrónica.

V-B4. Composición de Aumentaciones

Se implementaron métodos compuestos que permiten combinar varias aumentaciones para crear un pipeline complejo y controlado:

- Secuencial: Aplica múltiples aumentaciones de manera secuencial.
- Aplicación probabilística: Aplica una aumentación con una probabilidad determinada, introduciendo variabilidad controlada.
- Selección aleatoria: Elige una aumentación de un conjunto con probabilidades ponderadas.

Estas estrategias permiten generar un dataset enriquecido sin comprometer la coherencia entre imágenes y máscaras.

V-C. Métricas de Evaluación

V-C1. Exactitud (Accuracy)

V-C2. Intersección sobre Unión (IoU)

V-C3. Coeficiente Dice (F1)

V-C4. Precisión y Recall

V-D. Diseño del Framework AutoML

VI. RESULTADOS

VII. CONCLUSIONES